AxiomEval — Mathématiques et IA, semaines 01 à 26

Chaque section : variables, hypothèses, raisonnement, exemple numérique réel ou vérifiable, lien avec le code, limites. Les sections 1 à 7 portent sur du code **implémenté** ; les sections 8 à 12 préparent S10–S18 (**non implémenté**). Références AXM : `Math IA\AXM\16 - Refonte mathématique et visuelle\AXM-0x\A - Manuel integral.pdf`.

- AxiomEval — Mathématiques et IA, semaines 01 à 26
  - 1. Empreintes et chaîne d'événements (S03) — AXM : aucune (cryptographie appliquée)
  - 2. Unités, groupes et différences appariées (S04–S05) — AXM 03-C04, 04-C01
  - 3. Inégalité de Hoeffding et décision de non-infériorité (S05) — AXM 03-C06, 04-C04
  - 4. Bootstrap groupé (S05, S09) — AXM 04-C05
  - 5. Borne exacte de Clopper-Pearson (S05, S07) — AXM 04-C04 (« borne binomiale exacte »)
  - 6. Régression logistique, log loss, Brier (S09) — AXM 05-C03, 05-C04, 06-C01
  - 7. TF-IDF (S09)
  - 8. Préparation S10 — rétropropagation dans un GRU (non implémenté) — AXM 05-C05, 05-C07, 02-C02
  - 9. Préparation S11 — attention (non implémenté) — AXM 05-C08
  - 10. Préparation S13 — perte contrastive InfoNCE (non implémenté) — AXM 05-C09
  - 11. Préparation S15–S16 — calibration et prédiction conforme (non implémenté) — AXM 06-C01, 06-C04
  - 12. Préparation S17–S18 — décision coûteuse et OOD (non implémenté) — AXM 03-C07, 06-C05, 01-C08

1. Empreintes et chaîne d'événements (S03) — AXM : aucune (cryptographie appliquée)

Objet. $h_0 = 0^{64}$, $h_i = \mathrm{SHA256}(\mathrm{json}(e_i, h_{i-1}))$. L'empreinte finale h_n dépend de tous les événements et de leur ordre.

Raisonnement. Modifier e_k change h_k, donc h_{k+1}, …, h_n (effet en cascade). Réordonner deux événements change les entrées hachées. Trouver un $e'_k \neq e_k$ donnant le même h_k demanderait une collision SHA-256, infaisable en pratique ($\approx 2^{128}$ opérations par le paradoxe des anniversaires).

Code. `collect/trace.py::TraceEvent`, `validate_trace`, `trace_digest`. **Limite.** Une empreinte prouve l'intégrité, pas l'auteur : sans signature, quelqu'un peut recalculer une chaîne entière.

2. Unités, groupes et différences appariées (S04–S05) — AXM 03-C04, 04-C01

Variables. Groupes $g = 1..G$. Pour la release r, $Y_{g,j}^{(r)} \in \{0, 1\}$ succès de l'exécution j du groupe g (paraphrases × tirages, m_g exécutions). Taux du groupe : $\bar{Y}_g^{(r)} = \frac{1}{m_g} \sum_j Y_{g,j}^{(r)}$. Différence appariée : $D_g = \bar{Y}_g^{(c)} - \bar{Y}_g^{(b)} \in [-1, 1]$. Estimande : $\Delta = \mathbb{E}[D_g]$ sur la population des groupes.

Pourquoi apparier. $\mathrm{Var}(D_g) = \mathrm{Var}(\bar{Y}^{(c)}) + \mathrm{Var}(\bar{Y}^{(b)}) - 2\,\mathrm{Cov}$. Les deux releases passent le même groupe : la difficulté du groupe crée une covariance positive qui **réduit** la variance de la différence.

Pourquoi le groupe et non l'exécution. Les m_g exécutions d'un groupe sont corrélées (même situation). Compter $n = \sum m_g$ observations indépendantes sous-estimerait la variance. Avec corrélation intra-groupe ρ, la variance d'une moyenne de m valeurs est $\frac{\sigma^2}{m}(1 + (m-1)\rho)$: si ρ est grand, m répétitions valent à peine plus qu'une.

Code. `stats/paired.py::group_rates`, `paired_comparison`.

3. Inégalité de Hoeffding et décision de non-infériorité (S05) — AXM 03-C06, 04-C04

Énoncé. $X_1..X_n$ indépendantes, $X_i \in [a,b]$, $\bar{X}$ leur moyenne, $\mu = \mathbb{E}[\bar{X}]$. Pour $t > 0$: $P(\bar{X} - \mu \leq -t) \leq \exp\left(-\frac{2nt^2}{(b-a)^2}\right)$.

Esquisse de preuve. Méthode de Chernoff : pour $\lambda > 0$, $P(\mu - \bar{X} \geq t) \leq e^{-\lambda t}\,\mathbb{E}\big[e^{\lambda(\mu-\bar{X})}\big]$ (inégalité de Markov sur l'exponentielle). Par indépendance, l'espérance se factorise. Le lemme de Hoeffding borne chaque facteur : pour une variable centrée dans un intervalle de largeur w, $\mathbb{E}[e^{sZ}] \leq e^{s^2w^2/8}$. On obtient $\exp(-\lambda t + \lambda^2 w^2/(8n))$, minimisé en $\lambda = 4nt/w^2$, d'où $\exp(-2nt^2/w^2)$.

Rayon. Poser la borne égale à α : $t = w\sqrt{\ln(1/\alpha)/(2n)}$. Avec $w = 2$ (car $D_g \in [-1,1]$) : $t = 2\sqrt{\ln(1/\alpha)/(2n)} = \sqrt{2\ln(1/\alpha)/n}$.

Vérification numérique (données réelles). $n = 27$, $\alpha = 0{,}05$, $\ln 20 = 2{,}9957$: $t = \sqrt{2 \times 2{,}9957/27} = \sqrt{0{,}22190} = 0{,}4711$. Le fichier `reports/s05/compare_r1-baseline_r4-guarded.json` contient `hoeffding_radius = 0.4711`.

Décision. Hypothèse défavorable $H_0 : \Delta \leq -m$. On conclut à la non-infériorité si $\bar{D} - t > -m$. Sous H_0, $P(\bar{D} - t > -m) \leq P(\bar{D} - \Delta > t) \leq \alpha$: le risque de fausse promotion est au plus α.

Taille nécessaire. $\bar{D} - t > -m \iff n > \frac{w^2 \ln(1/\alpha)}{2(\bar{D}+m)^2}$. Réel : r1→r4, $\bar{D} = -0{,}0123$, $m = 0{,}10$: $n > 4 \times 2{,}9957/(2 \times 0{,}0877^2) \approx 780$.

Hypothèses et limites. Indépendance des groupes (nos groupes viennent de 18 familles : ceux d'une même famille partagent un modèle de question, l'indépendance est approximative). Borne valable pour tout n, mais conservatrice : elle n'utilise que la largeur w, pas la variance réelle (une borne de Bernstein ou empirique-Bernstein serait plus serrée).

4. Bootstrap groupé (S05, S09) — AXM 04-C05

Principe. Approcher la loi de $\bar{D}$ en tirant G groupes **avec remise** parmi les G observés, B fois, et prendre les quantiles 2,5 % et 97,5 % des moyennes obtenues (intervalle percentile).

Pourquoi par groupe. Rééchantillonner les exécutions casserait la dépendance intra-groupe et donnerait un intervalle trop étroit.

Réel. r2→r4 : $[0{,}019;\ 0{,}148]$ alors que Hoeffding donne une borne inférieure de −0,391 : le bootstrap est bien plus étroit, mais c'est une **approximation** (justifiée asymptotiquement, discutable à 27 groupes). C'est pourquoi la décision utilise Hoeffding.

Code. `stats/paired.py` (L96–L99), `ml/baselines.py::group_bootstrap`.

5. Borne exacte de Clopper-Pearson (S05, S07) — AXM 04-C04 (« borne binomiale exacte »)

Énoncé. k succès sur n essais de Bernoulli indépendants. Borne supérieure unilatérale à $1-\alpha$: le plus grand p tel que $P(X \leq k \mid p) = \sum_{i=0}^{k} \binom{n}{i} p^i (1-p)^{n-i} > \alpha$. La fonction décroît en p, d'où la bissection.

Cas $k = 0$. $(1-p)^n = \alpha \Rightarrow p = 1 - \alpha^{1/n}$. Pour $n = 27$: $1 - 0{,}05^{1/27} = 1 - e^{-2{,}9957/27} = 1 - e^{-0{,}11095} = 0{,}105$ — le rapport affiche « ≤ 11 % » pour 0/27 brèche de r4. Pour $n = 9$: $1 - 0{,}05^{1/9} = 0{,}283$ (« ≤ 28 % »).

Limite. Les tirages d'un même scénario sont corrélés : l'effectif utile est plus petit que n, la borne vraie plus haute.

6. Régression logistique, log loss, Brier (S09) — AXM 05-C03, 05-C04, 06-C01

Modèle. $p(x) = \sigma(w^\top x + b), \sigma(z) = 1/(1+e^{-z})$.

Perte (log loss). $\ell(w) = -\frac{1}{n}\sum_i [y_i \ln p_i + (1-y_i)\ln(1-p_i)] + \frac{1}{2Cn}\|w\|^2$ (forme proportionnelle à celle de scikit-learn). C'est l'entropie croisée : maximiser la vraisemblance d'un modèle de Bernoulli.

Gradient. Comme $\sigma'(z) = \sigma(z)(1-\sigma(z))$, $\partial\ell/\partial w = \frac{1}{n}\sum_i (p_i - y_i)\, x_i + \frac{w}{Cn}$. La perte est convexe : un minimum global unique, atteint par l'optimiseur (`lbfgs`).

C. Petit C = forte régularisation. Choisi par validation croisée groupée sur l'entraînement (`select_c`) : C = 1 retenu.

Brier. $\frac{1}{n}\sum (p_i - y_i)^2$. Score propre : il est minimisé en espérance par la vraie probabilité. Une prédiction constante égale à la prévalence π donne $\pi(1-\pi)$: réel, $0{,}54 \times 0{,}46 \approx 0{,}248$, proche des 0,256 de la baseline majoritaire (dont π vient de l'entraînement, pas du test).

PR-AUC (précision moyenne). $\sum_k (R_k - R_{k-1}) P_k$ sur les seuils. Une prédiction aléatoire vaut en moyenne la prévalence (≈ 0,54 ici), d'où la baseline majoritaire à 0,542.

Vérification (test unitaire). $y = (0,0,1,1)$, $p = (0{,}1; 0{,}4; 0{,}35; 0{,}8)$: ROC-AUC = 3 paires bien ordonnées sur 4 = 0,75 ; PR-AUC = $(1 + 2/3)/2 = 0{,}833$ (`tests/test_ml_s09.py::test_metrics_on_known_values`).

7. TF-IDF (S09)

$\mathrm{tfidf}(t,d) = (1 + \ln \mathrm{tf}_{t,d}) \cdot \left(\ln \frac{1+N}{1+\mathrm{df}_t} + 1\right)$, puis normalisation L2 (`sublinear_tf=True`, valeurs par défaut de scikit-learn). Le vocabulaire et les df sont appris sur l'entraînement uniquement ; un mot nouveau au test est ignoré (test `test_featurizer_learns_vocabulary_from_train_only`).

---

8. Préparation S10 — rétropropagation dans un GRU (non implémenté) — AXM 05-C05, 05-C07, 02-C02

GRU : $z_t = \sigma(W_z x_t + U_z h_{t-1})$, $r_t = \sigma(W_r x_t + U_r h_{t-1})$, $\tilde{h}_t = \tanh(W x_t + U(r_t \odot h_{t-1}))$, $h_t = (1-z_t)\odot h_{t-1} + z_t \odot \tilde{h}_t$. La rétropropagation dans le temps applique la règle de la chaîne à travers t ; la porte z_t limite la disparition du gradient. **Masquage** : les positions de remplissage ne doivent contribuer ni à la perte ni au dernier état utilisé. **Vérification à faire** : comparer gradient analytique et différences finies $\frac{\ell(w+\varepsilon)-\ell(w-\varepsilon)}{2\varepsilon}$ (AXM 05-C05).

9. Préparation S11 — attention (non implémenté) — AXM 05-C08

$\mathrm{Attention}(Q,K,V) = \mathrm{softmax}(QK^\top/\sqrt{d_k} + M)V$; M vaut $-\infty$ aux positions masquées. Le facteur $1/\sqrt{d_k}$ garde la variance des scores proche de 1 quand les composantes sont de variance 1 (somme de d_k produits). Coût $O(L^2 d)$ en longueur L.

10. Préparation S13 — perte contrastive InfoNCE (non implémenté) — AXM 05-C09

$\ell_i = -\ln \frac{\exp(\mathrm{sim}(z_i, z_i^+)/\tau)}{\sum_k \exp(\mathrm{sim}(z_i, z_k)/\tau)}$. *Collapse* : si toutes les représentations sont égales, la perte vaut $\ln K$ et ne diminue plus ; surveiller la variance des représentations.

11. Préparation S15–S16 — calibration et prédiction conforme (non implémenté) — AXM 06-C01, 06-C04

ECE à B classes : $\sum_b \frac{n_b}{n} |\mathrm{acc}_b - \mathrm{conf}_b|$ (dépend du découpage annoncé). Conformal split : scores $s_1..s_n$ sur la calibration, $\hat{q}$ = le $\lceil (n+1)(1-\alpha) \rceil$-ième plus petit ; sous **échangeabilité**, $P(Y \in C(X)) \geq 1-\alpha$. Exemple : $n = 100, \alpha = 0{,}1 \to \lceil 90{,}9 \rceil = 91$-ième score. La garantie disparaît sous changement de release si l'échangeabilité ne tient plus.

12. Préparation S17–S18 — décision coûteuse et OOD (non implémenté) — AXM 03-C07, 06-C05, 01-C08

Décision bayésienne : envoyer en revue si $p \cdot c_{\text{faux PROMOTE}} > (1-p) \cdot c_{\text{revue inutile}}$, soit $p > \frac{c_r}{c_r + c_f}$. Distance de Mahalanobis $d(x) = \sqrt{(x-\mu)^\top \Sigma^{-1} (x-\mu)}$ avec Σ régularisée $\Sigma + \lambda I$ (inversibilité, AXM 01-C08).